


ANALIZA KREDITNOG PORTFOLIA

SISTEMI BAZA PODATAKA
—PREDLOG TEME PROJEKTA

DUŠANKA IGNJATOVIĆ IN41/2021



SADRŽAJ

SADRŽAJ

SADRŽAJ

1

PREGLED SKUPA PODATAKA

- Upoznavanje sa temom
- Osnovne informacije o skupu podataka i pregled fajlova

2

SEMANTIKA KOLONA

- Semantika kolona fajla origination_data-2.csv
- Semantika kolona fajla monthly_performance-2.csv

3

LOGIČKA SHEMA PODATAKA

- Predlog osnovne logičke sheme podataka
- Primer prostiranja podataka kroz datoteke

4

AGREGACIJA PODATAKA

- Pitanja na koja bi projekat trebalo da odgovori

1

PREGLED SKUPA PODATAKA

PREGLED SKUPA PODATAKA

PREGLED SKUPA PODATAKA

1

OSNOVNA TERMINOLOGIJA

KREDITNI PORTFOLIO BANKE

- Kreditni portfolio predstavlja skup svih bankarskih derivata koji je finansijski posrednik (u ovom slučaju banka) odobrio svojim korisnicima.
- Predstavlja aktivu banke i glavni je odražaj njenog poslovanja.
- Praćenje i analiza kreditnog portfolia imaju zadatak da uvide nepravilnosti i rane opasnosti u kreditnim aktivnostima banke, čime se dovodi do smanjenja rizika.

KREDITNA SPOSOBNOST

- U bankarstvu, pojam kreditne sposobnosti predstavlja sposobnost pojedinca da otplaćuje kreditne obaveze i služi za procenu vrednosti koju je pojedinac u stanju pozajmiti, a potom i uredno vratiti.
- Kreditna sposobnost se računa na osnovu **redvnosti prihoda, statusa zaposlenja, poslodavca, načina oporezivanja, postojećih obaveza i kreditne istorije** korisnika.
- Za korisnika koji je, u nekom trenutku **po** uzimanju kredita došao u situaciju da isti više ne može vratiti obaveye prema zajmodavcu kaže se da je **likvidiran (eng. default)**.

KREDITNI RIZIK

- U bankarstvu, kreditni rizik definiše stopu rizika koju klijent nosi sa sobom prilikom uzimanja kredita.
- Kreditni rizik diktira količinu rezervi koju je banka obavezana da odvoji prilikom izdavanja kredita.
- Klasifikacija korisnika na osnovu rizika koji nose vrši se na osnovu finansijskih izveštaja korisnika, pre svega **novčanih tokova**, i **redvnosti izmirenja dosadašnjih obaveza**.



O SKUPU PODATAKA

- Skup podataka predstavlja *sintetičke* podatke o kreditnim aktivnostima 135 000 korisnika raspoređenih u periodu od Januara 2022. do Decembra 2024. godine. Podaci su raspoređeni u dva fajla – *origination_data-2.csv* i *monthly_performance-2.csv*
- *origination_data-2.csv* predstavlja skup od 135 000 zapisa sa osnovnim informacijama o korisnicima usluga. Sadrži 19 kolona koje opisuju demografske i finansijske profile klijenata.
- *monthly_performance-2.csv* predstavlja skup od 2 355 761 zapisa. Sadrži 13 kolona koje detaljno opisuju mesečna ponašanja korisnika od trenutka odobravanja kredita, do trenutka potpune otplate istog, odnosno odlaska u default.



ORIGINATION_DATA-2.CSV

Naziv	Tip podataka	Značenje
customer_id	string	Identifikaciono polje korisnika
application_date	date	Datum podnošenja zahteva za uzimanje kredita
age	integer	Starost korisnika u godinama
gender	string (kategoričko polje)	Rod korisnika (u ovom skupu podataka, moguće vrednosti su male i female)
employment_status	string (kategoričko polje)	Radni status (moguće vrednosti su employed, self-employed i unemployed)
annual_income	float	Godišnja zarada korisnika
monthly_income	float	Mesečna zarada korisnika

ORIGINATION_DATA-2.CSV

Naziv	Tip podataka	Značenje
loan_amount	float	Nominalna vrednost kredita
interest_rate	float	Kamatna stopa kredita
loan_term	integer	Period otplate kredita
emi	float	<i>Equated monthly installment</i> – visina jedne mesečne rate kredita
credit_score_origination	integer	Kreditni rejting korisnika (po Američkom FICO standardu)
dti	float	<i>Debt-to-income</i> – ratio pokazatelj koji daje odnos ukupnog zaduženja korisnika i njegovih prihoda
revolving_utilization_origination	float	Stepen iskorišćenosti kreditne kartice korisnika u trenutku prijave za pozajmicu (iskorišćena sredstva/ukupna sredstva)

ORIGINATION_DATA-2.CSV

Naziv	Tip podataka	Značenje
credit_inquiries_12m	integer	Broj zahteva za podizanje kredita u poslednjih 12 meseci
deterioration_pattern	string (kategoričko polje)	Trend korisnikovog dosadašnjeg izmirivanja dugova i kretanja njegovog kreditnog rejtinga. (moguće vrednosti su stable, gradual_decline, sudden_shock i credit_seeking)
default_12m	integer (binary)	Klasifikaciono polje koje govori da li je korisnik u roku od 12m od uzimanja kredita završio u defaultu
vintage_year	integer	Godina odobrenja kredita
vintage_month	string (yyyy-mm)	Mesec odobrenja kredita

MONTHLY_PERFORMANCE-2.CSV

Naziv	Tip podataka	Značenje
customer_id	string	Identifikaciona oznaka korisnika
observation_month	string (yyyy-mm)	Mesec beleženja podataka
dpd_current	integer	<i>Days past due</i> – period kašnjenja isplate rata, izražen u danima (0, 30, 60, 90+)
payment_made	integer (binary)	Oznaka da li je korisnik platio tekuću ratu kredita
payment_amount	float	Visina uplate u tekućem mesecu
scheduled_emi	float	Očekivana visina rate
credit_score	integer	Kreditni rejting u tekućem mesecu

MONTHLY_PERFORMANCE-2.CSV

Naziv	Tip podataka	Značenje
credit_score_delta_3m	integer	Promena kreditnog rejtinga zabeležena u poslednja tri meseca
revolving_utilization	float	Stepen iskorišćenosti sredstava sa kreditne kartice korisnika u tekućem mesecu
revolving_util_delta_3m	float	Promena u iskorišćenosti sredstava sa kreditne kartice u poslednja tri meseca
has_defaulted	integer (binary)	Oznaka da li je u tekućem mesecu korisnik otišao u default
will_default_original	Integer (binary)	Oznaka da li se od korisnika očekuje da ode u default (vrednosti prekopirane iz default_12m u fajlu origination_data-2.csv)

NAPOMENA:

Zbog svoje sintetičke prirode, podaci predstavljeni u skupu podataka ne predstavljaju realnu sliku bankarskog poslovanja, već isključivo njegovu simulaciju. Samim tim neke od kolona predstavljaju idealizovanu verziju stvarnih pojava, dok su neke kolone značajno pojednostavljene. Primer ove pojave je pretpostavka pod kojom se za korisnika kaže da je otišao u likvidaciju gde, u realnom svetu, neretko dolazi do situacije da korisnik koji kasni preko 90 dana sa isplatama na kraju ipak uspe otplatiti kredit do kraja i ispraviti svoje performanse. Slično, visina mesečne uplate u originalnom skupu može biti maksimalno u visini dogovorene rate, dok je u stvarnom svetu moguće i otplatiti kredite prevremeno, uz odgovarajuće ugovorne obaveze, a isto tako može platiti i više rata odjednom ukoliko već kasni. „Dpd_current“ i „payment_amount“ kolone se prerađene tako da je moguće naići na zakasnele uplate u periodu kraćem od 90 dana, a onda to kašnjenje i nadomestiti dodatnim uplatama. Dodatno u skupu se nalaze kolone koje, u teoriji, olakšavaju proračune poput „(...)_delta_3m“ kolona. Vrednosti ovih kolona nailaze na greške u proračunu zbog čega će biti izbačene iz, dok će na njihovo mesto ukoliko za to bude potrebe doći kolone „(...)_delta“ koje će nastati kao prosta razlika između zabeleženih podataka za trenutni i prethodni mesec (ili alternativno tromesečna verzija). U daljem radu se može desiti da budu primećena dalja nelogična ponašanja u skupu, koja će tada biti i analizirana i otklonjena.



LOGIČKA SHEMA PODATAKA
LOGIČKA SHEMA PODATAKA
LOGIČKA SHEMA PODATAKA



OSNOVNA LOGIČKA SHEMA

- U osnovnoj verziji, podaci će biti raspoređeni u skladu sa originalnom raspodelom u samom skupu podataka, odnosno u dve kolekcije – `monthly_performance` i `origination_data`.

```
_id: ObjectId('6a1c5aab9855a4454ce7f578')
customer_id: "CUST1000000"
observation_month: "2022-05"
months_on_book: 1
dpd_current: 0
payment_made: 1
payment_amount: 1668.61
scheduled_emi: 1668.61
credit_score: 722
credit_score_delta_3m: 2
revolving_utilization: 0.443
revolving_util_delta_3m: 0.01
has_defaulted: 0
will_default_original: 0
```

monthly_performance

$(1,1)$ ----- $(0, N)$

```
_id: ObjectId('6a1c5aa19855a4454ce5e620')
customer_id: "CUST1000000"
application_date: "2022-04-08"
age: 42
gender: "Male"
employment_status: "Self-Employed"
annual_income: 83834
monthly_income: 6986.17
loan_amount: 50000
interest_rate: 12.33
loan_term: 36
emi: 1668.61
dti: 0.35
credit_score_origination: 720
revolving_utilization_origination: 0.433
credit_inquiries_12m: 0
deterioration_pattern: "stable"
default_12m: 0
vintage_year: 2022
vintage_month: "2022-04"
```

origination_data

1

AGREGACIJA PODATAKA
AGREGACIJA PODATAKA
AGREGACIJA PODATAKA

UPITI SA KOJIMA ĆE SE RADITI

1. Za svakog klijenta koji je ušao u default, odrediti mesec pre ulaska u default u kom je imao najveći pad kreditnog rejtinga u prethodna 3 meseca.
2. Pronaći klijente kod kojih je iskorišćenost kreditne kartice porastao više od 40%, a kreditna sposobnost opala za više od 100 poena u periodu od 3 meseca pre likvidacije.
3. Za korisnike sa lošim kreditnim rejtingom u trenutku odobrenja kredita (<579) odrediti odnos ukupne sume izvršenih uplata i predviđene vrednosti uplata u prvih 12 meseci, kao i stopu defaulta.
4. Za korisnike sa izuzetnim kreditnim rejtingom u trenutku odobrenja kredita (>800) pronaći broj korisnika čiji je rejting u nekom trenutku opao u nižu kategoriju (≤ 799).
5. Za svakog klijenta izračunati najduži uzastopni niz meseci bez propuštene uplate.
6. Pronaći profil korisnika (starosnu grupu, rod, status zaposlenosti i opseg godišnjih prihoda) koji ima najmanji prosečan DTI i najveći procenat urednih uplata tokom prvih 12 meseci otplate.